

# 优化笔记

Leoeon

2015.11.11

# Contents

<b>1</b>	<b>凸优化</b>	<b>4</b>
1.1	凸集	4
1.1.1	集合	4
1.1.1.1	仿射	4
1.1.1.2	凸	4
1.1.1.3	锥	4
1.1.2	正常锥	5
1.1.3	超平面	5
1.1.4	对偶锥	5
1.1.5	最值与极值	5
1.1.5.1	最小元	5
1.1.5.2	极小元	5
1.1.6	单调性	6
1.2	凸函数	6
1.2.1	凸函数	6
1.2.2	上境图	6
1.2.3	共轭函数	6
1.2.4	拟凸函数	7
1.2.5	对数凸函数	7
1.2.6	K凸函数	8
1.3	凸优化问题	8
1.3.1	凸优化问题	8
1.3.2	拟凸优化问题	8
1.4	拉格朗日乘子法	9
1.5	例子	10
1.5.1	不等式	10
1.5.1.1		10
1.5.1.2		10
<b>2</b>	<b>迭代法</b>	<b>11</b>
2.1	梯度下降法	11
2.2	牛顿法	11

2.2.1	拟牛顿法 . . . . .	12
2.2.1.1	BFGS . . . . .	12
2.2.1.2	DFP . . . . .	12
2.3	有约束的迭代法 . . . . .	12
2.3.1	惩罚函数法 . . . . .	12
2.3.2	边界跟踪法 . . . . .	13
2.3.2.1	法一 . . . . .	13
2.3.2.2	法二 . . . . .	13

# Chapter 1

## 凸优化

### 1.1 凸集

#### 1.1.1 集合

##### 1.1.1.1 仿射

多点 $\{x_k\}$ 的仿射组合:  $\{\sum_k \theta_k x_k | \sum_k \theta_k = 1\}$

集合 $C$ 的仿射包:  $\text{aff}[C] = \{\sum_k \theta_k x_k | \forall x_k \in C, \sum_k \theta_k = 1\}$

集合 $C$ 是仿射集合:  $C \supseteq \text{aff}[C]$



##### 1.1.1.2 凸

多点 $\{x_k\}$ 的凸组合:  $\{\sum_k \theta_k x_k | \sum_k \theta_k = 1, \theta_k \geq 0\}$

集合 $C$ 的凸包:  $\text{conv}[C] = \{\sum_k \theta_k x_k | \forall x_k \in C, \sum_k \theta_k = 1, \theta_k \geq 0\}$

集合 $C$ 是凸集:  $C \supseteq \text{conv}[C]$

一般化: 集合 $C$ 是凸集, 随机变量 $x$ ,  $P(x \in C) = 1$ , 则  $E[x] = \int_{x \in C} p(x)x dx \in C$



##### 1.1.1.3 锥

多点 $\{x_k\}$ 的锥组合:  $\{\sum_k \theta_k x_k | \theta_k \geq 0\}$

集合 $C$ 的锥包:  $\text{cone}[C] = \{\sum_k \theta_k x_k | \forall x_k \in C, \theta_k \geq 0\}$

集合 $C$ 是凸锥:  $C \supseteq \text{cone}[C]$



## 1.1.2 正常锥

正常锥：锥 $K$ 为凸、闭、实（有非空内部）、尖（不包含直线）

广义不等式： $x_1 \succeq_K x_2 \iff x_2 - x_1 \in K$

## 1.1.3 超平面

超平面分离定理：凸集 $C \cap$  凸集 $D = \emptyset$ ，则 $\exists a \neq 0, b$ ，对 $\forall x \in C$  有 $a^T x \leq b$ ，对 $\forall x \in D$  有 $a^T x \geq b$

支撑超平面：取 $a \neq 0$ ， $x_0 \in$  边界 $[C]$ ，对 $\forall x \in C$ ，有 $a^T(x - x_0) \leq 0$ ，则 $\{x | a^T(x - x_0) = 0\}$ 为 $C$ 的支撑超平面

支撑超平面定理：对 $\forall$ 非空凸集 $C$ ， $\forall x_0 \in$  边界 $[C]$ ，在 $x_0$ 处 $\exists C$ 的支撑超平面

## 1.1.4 对偶锥

锥 $K$ 的对偶锥 $K^* = \{z | x^T z \geq 0, \forall x \in K\}$  是闭凸锥

$$\begin{cases} x_1 \succeq_K x_2 & \iff \text{对} \forall z \succeq_{K^*} 0, \text{有} z^T x_1 \leq z^T x_2 & (z \neq 0 \text{时}, z^T x_1 < z^T x_2) \\ z_1 \succeq_{K^*} z_2 & \iff \text{对} \forall x \succeq_K 0, \text{有} z_1^T x \leq z_2^T x & (z \neq 0 \text{时}, z_1^T x < z_2^T x) \end{cases}$$



$K^{**}$ 是 $K$ 的凸包的闭包


## 1.1.5 最值与极值

## 1.1.5.1 最小元

$x_0 \in S$ ，对 $\forall x \in S$  均有 $x_0 \preceq_K x$

$\iff$  对 $\forall \lambda \succeq_{K^*} 0$ ， $\forall x \in S$ ， $x_0 = \arg \min_x \lambda^T x$

$\iff$  对 $\forall \lambda \succeq_{K^*} 0$ ，超平面 $\{x | \lambda^T(x - x_0) = 0\}$ 是 $x_0$ 处对 $S$ 的严格支撑超平面




## 1.1.5.2 极小元

$x_0 \in S$ ，对 $\forall x \in S$  均有 $(x \preceq_K x_0 \implies x = x_0)$

$\iff \exists \lambda_0 \succeq_{K^*} 0$ ， $\forall x \in S$ ， $x_0 = \arg \min \lambda_0^T x$

$x_0 \in S$ ，对 $\forall x \in$  凸集 $S$  均有 $(x \preceq_K x_0 \implies x = x_0)$

$\iff \exists \lambda_0 \succeq_{K^*} 0$ ， $\forall x \in$  凸集 $S$ ， $x_0 = \arg \min \lambda_0^T x$



### 1.1.6 单调性

对可微函数 $f$ ,  $\text{dom}[f]$  为凸集

$f$ 是 $k$ -非减的  $\iff$  对 $\forall x \in \text{dom}[f]$  有 $\nabla f(x) \succeq_{K^*} 0$

$f$ 是 $k$ -增的  $\iff$  对 $\forall x \in \text{dom}[f]$  有 $\nabla f(x) \succ_{K^*} 0$

## 1.2 凸函数

### 1.2.1 凸函数

$f: \mathbb{R}^n \rightarrow \mathbb{R}$

若定义域 $\text{dom}[f]$ 是凸集, 且对 $\forall x_1, x_2 \in \text{dom}[f], \forall \theta \in [0, 1]$ , 有 $f(\theta x_1 + (1-\theta)x_2) \leq \theta f(x_1) + (1-\theta)f(x_2)$

一般化:  $f(E[x]) \leq E[f(x)]$  或  $f(x) \leq E[f(x+z)]$  ( $z$ 是均值为0随机变量)

$\iff$   $f$ 在与定义域相交的任何直线上都是凸的

即对 $\forall x \in \text{dom}[f]$  与 $\forall v$ ,  $g(t) = f(x + tv)$  是凸的

$\iff$   $\text{dom}[f]$ 是凸集, 且对 $\forall x_1, x_2 \in \text{dom}[f]$  有 $f(x_2) \geq f(x_1) + \nabla f(x_1)^T(x_2 - x_1)$

$\iff$   $\text{dom}[f]$ 是凸集, 且对 $\forall x \in \text{dom}[f]$  有 $\nabla^2 f(x) \succeq 0$

(可将 $f(x)$ 延拓为 $\tilde{f}(x) = \begin{cases} f(x) & , x \in \text{dom}[f] \\ +\infty & , x \notin \text{dom}[f] \end{cases}$ )




Figure 1.1: 凸函数

### 1.2.2 上境图

函数 $f$ 的上境图 $\text{epi}[f] \stackrel{\text{def}}{=} \{(x, t) | x \in \text{dom}[f], t \geq f(x)\}$

$f$ 是凸函数  $\iff$   $\text{epi}[f]$ 是凸函数

### 1.2.3 共轭函数



$f^*: \mathbb{R}^n \rightarrow \mathbb{R}, f^*(z) \stackrel{\text{def}}{=} \sup_{x \in \text{dom}[f]} (z^T x - f(x)) = \nabla f(x)^T x - f(x)|_{z=\nabla f(x)}$

$f^{**}: \mathbb{R}^n \rightarrow \mathbb{R}, f^{**}(x) \stackrel{\text{def}}{=} \sup_{z \in \text{dom}[f^*]} (x^T z - f^*(z))$

无论 $f$ 是否为凸函数, 共轭函数 $f^*$ 必为闭凸函数

恒有 $f(x) \geq f^{**}(x)$

若 $f$ 为凸且闭, 则 $f^{**}(x) = f(x)$

Figure 1.2:  $f^*$ Figure 1.3:  $f^{**}$ 

### 1.2.4 拟凸函数

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

若对  $\forall a \in \mathbb{R}$ ,  $\{x \in \text{dom}[f] | f(x) \leq a\}$  都是凸集

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x_1, x_2 \in \text{dom}[f], \forall \theta \in [0, 1] \text{ 有 } f(\theta x_1 + (1 - \theta)x_2) \leq \max\{f(x_1), f(x_2)\}$$

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x_1, x_2 \in \text{dom}[f] \text{ 有 } (f(x_2) \leq f(x_1) \Rightarrow \nabla f(x_1)^T (x_2 - x_1) \leq 0)$$

$$\iff \text{对 } \forall x \in \text{dom}[f], \forall u \in \mathbb{R}^n \text{ 有 } (u^T \nabla f(x) = 0 \Rightarrow u^T \nabla^2 f(x) u \geq 0)$$




Figure 1.4: 拟凸函数

### 1.2.5 对数凸函数

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

若对 $\forall x \in \text{dom}[f]$  有 $f(x) > 0$  且 $\log f(x)$  是凸函数

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x \in \text{dom}[f] \text{ 有 } f(x) > 0, \text{ 且对 } \forall x_1, x_2 \in \text{dom}[f], \forall \theta \in [0, 1] \text{ 有 } f(\theta x_1 + (1-\theta)x_2) \leq f(x_1)^\theta f(x_2)^{1-\theta}$$

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x_1, x_2 \in \text{dom}[f] \text{ 有 } \log f(x_2) \geq \log f(x_1) + \frac{\nabla f(x_1)^T}{f(x_1)}(x_2 - x_1)$$

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x \in \text{dom}[f] \text{ 有 } f(x) \nabla^2 f(x) \succeq \nabla f(x) \nabla f(x)^T$$

$\Rightarrow f$  是凸函数,  $f$  是拟凸函数

## 1.2.6 K凸函数

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $K \subseteq \mathbb{R}^m$  是一正常锥

若对 $\forall x_1, x_2, \forall \theta \in [0, 1]$  有 $f(\theta x_1 + (1-\theta)x_2) \preceq_K \theta f(x_1) + (1-\theta)f(x_2)$

$$\iff \text{对 } \forall w \succeq_{K^*} 0, w^T f \text{ 是凸的}$$

$$\iff \text{dom}[f] \text{ 是凸集, 且对 } \forall x_1, x_2 \in \text{dom}[f] \text{ 有 } f(x_2) \succeq_K f(x_1) + Df(x_1)(x_2 - x_1) \text{ (D是Jacobian矩阵)}$$

## 1.3 凸优化问题

### 1.3.1 凸优化问题

$$\begin{aligned} & \min_x f(x) && (f(x) \text{ 为凸函数}) \\ \text{s.t. } & g_i(x) \leq 0 && (g_i(x) \text{ 为凸函数}) \\ & h_j(x) = a_j^T x - b_j = 0 \end{aligned}$$

$x^*$  是全局最优解, 即 $x^* = \arg\inf_x \{f(x) | g_i(x) \leq 0, h_j(x) = 0\}$

$$\iff x^* \text{ 是任意局部最优解, 即 } x^* = \arg\inf_x \{f(x) | g_i(x) \leq 0, h_j(x) = 0, \|x - x^*\| \leq \varepsilon (\varepsilon > 0)\}$$

$$\iff x^* \in \text{约束}, \text{ 对 } \forall x \in \text{约束} (x \neq x^*), \text{ 有 } \nabla f^T(x^*)(x - x^*) \geq 0$$

### 1.3.2 拟凸优化问题

$$\begin{aligned} & \min_x f(x) && (f(x) \text{ 为拟凸函数}) \\ \text{s.t. } & g_i(x) \leq 0 && (g_i(x) \text{ 为凸函数}) \\ & h_j(x) = a_j^T x - b_j = 0 \end{aligned}$$

$x^*$  是全局最优解, 即 $x^* = \arg\inf_x \{f(x) | g_i(x) \leq 0, h_j(x) = 0\}$

( ~~$\iff$~~   $x^*$  是任意局部最优解)

$$\iff x^* \in \text{约束}, \text{ 对 } \forall x \in \text{约束} (x \neq x^*), \text{ 有 } \nabla f^T(x^*)(x - x^*) \geq 0$$

将拟凸优化问题转为凸优化问题:



1. 令  $\phi_t : R^n \rightarrow R, t \in R$  为满足  $f(x) \leq t \iff \phi_t(x) \leq 0$  的一族函数

$$(\text{如 } \phi_t(x) = \begin{cases} 0 & , f(x) \leq t \\ +\infty & , f(x) > t \end{cases})$$

2. 解凸可行性问题

$$\begin{aligned} & x \\ \text{s.t. } & \phi_t(x) \leq 0 \\ & g_i(x) \leq 0 \\ & h_j(x) = 0 \end{aligned}$$

若有解, 则  $f(x^*) \leq t$ , 否则  $f(x^*) > t$

3. 由此用二分法划t限出  $f(x^*)$  所在

## 1.4 拉格朗日乘子法

原优化问题

$$\begin{aligned} & \min_x f(x) \\ \text{s.t. } & g_i(x) \leq 0 \\ & h_j(x) = 0 \end{aligned}$$

Lagrange函数

$$L(x, \lambda, \nu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \nu_j h_j(x)$$

Lagrange对偶函数

$$F(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) \quad \left( D = \bigcap_i \text{dom}[g_i] \bigcap_j \bigcap_j \text{dom}[h_j] \right)$$

Lagrange对偶问题

$$\begin{aligned} & \max_{\lambda, \nu} F(\lambda, \nu) \quad (\text{dom}[F] = \{(\lambda, \nu) | F(\lambda, \nu) > -\infty\}) \\ \text{s.t. } & \lambda \succeq 0 \end{aligned}$$

(无论原问题是否为凸优化问题, 对偶问题必是凸优化问题)

对  $\forall \lambda \succeq 0$  与  $\forall \nu$ , 有

$$F(\lambda, \nu) \leq \text{最优值 } f(x^*)$$

即

$$\text{最优值 } F(\lambda^*, \nu^*) \leq \text{最优值 } f(x^*)$$

即

$$\sup_{\lambda \succeq 0} \inf_x L(x, \lambda, \nu) \leq \inf_x \sup_{\lambda \succeq 0} L(x, \lambda, \nu)$$

当强对偶性成立, 即最优值  $F(\lambda^*, \nu^*) = \text{最优值 } f(x^*)$  时, 有

$$\begin{cases} \nabla_x f(x^*) + \sum_i \lambda_i^* \nabla_x g_i(x^*) + \sum_j \nu_j^* \nabla_x h_j(x^*) = 0 \\ g_i(x^*) \leq 0, \quad \lambda_i^* \geq 0, \quad \lambda_i^* g_i(x^*) = 0 \\ h_j(x^*) = 0 \end{cases}$$

$$\left( \begin{cases} g_i(x) \leq 0 \\ h_j(x) = 0 \end{cases} \text{ 与 } \begin{cases} \lambda \succeq 0 \\ \inf_{x \in D} [\sum_i \lambda_i g_i(x) + \sum_j \nu_j h_j(x)] > 0 \end{cases} \text{ 至多有一个可行} \right)$$

## 1.5 例子

### 1.5.1 不等式

#### 1.5.1.1

算数几何平均不等式：凸函数  $f(x) = -\log x$

$$\sum_{i=1}^n a_i x_i \geq \prod_{i=1}^n x_i^{a_i} \quad (x_i \geq 0)$$

$$\frac{1}{n} \sum_{i=1}^n x_i \geq \left( \prod_{i=1}^n x_i \right)^{\frac{1}{n}} \quad (x_i \geq 0)$$

#### 1.5.1.2

Holder不等式：凸函数  $f(x) = x^p$

$$\sum_{i=1}^n x_i y_i \leq \left( \sum_{i=1}^n x_i^p \right)^{\frac{1}{p}} \left( \sum_{i=1}^n y_i^q \right)^{\frac{1}{q}} \quad (x_i, y_i > 0) (p, q > 1) \left( \frac{1}{p} + \frac{1}{q} = 1 \right)$$

Minkowski和不等式：

$$\left[ \sum_{i=1}^n (x_i + y_i)^p \right]^{\frac{1}{p}} \leq \left( \sum_{i=1}^n x_i^p \right)^{\frac{1}{p}} + \left( \sum_{i=1}^n y_i^p \right)^{\frac{1}{p}} \quad (x_i, y_i \geq 0) (p > 1)$$

Minkowski积不等式：

$$\left[ \prod_{i=1}^n (x_i + y_i) \right]^{\frac{1}{n}} \geq \left( \prod_{i=1}^n x_i \right)^{\frac{1}{n}} + \left( \prod_{i=1}^n y_i \right)^{\frac{1}{n}} \quad (x_i, y_i \geq 0)$$

Jensen不等式：

$$\left( \sum_{i=1}^n x_i^{p_1} \right)^{\frac{1}{p_1}} > \left( \sum_{i=1}^n x_i^{p_2} \right)^{\frac{1}{p_2}} \quad (x_i > 0) (0 < p_1 < p_2)$$

## Chapter 2

# 迭代法

求 $\min_x f(x)$

### 2.1 梯度下降法

$$f(x) \simeq f(x^{(t)}) + \left[ \cdots \quad \frac{\partial f}{\partial x_i}(x^{(t)}) \quad \cdots \right] (\vec{x} - \vec{x}^{(t)})$$

故 $\Delta x$  模恒定的前提下，方向为 $-\begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix}$  时， $f(x)$  最小。

即

$$\vec{x}^{(t+1)} = \vec{x}^{(t)} - \lambda \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix}$$

### 2.2 牛顿法

$$\begin{aligned} f(x) &\simeq f(x^{(t)}) \\ &+ \left[ \cdots \quad \frac{\partial f}{\partial x_i}(x^{(t)}) \quad \cdots \right] (\vec{x} - \vec{x}^{(t)}) \\ &+ \frac{1}{2}(\vec{x} - \vec{x}^{(t)}) \begin{bmatrix} \vdots \\ \frac{\partial^2 f}{\partial x_i \partial x_j}(x^{(t)}) \quad \cdots \\ \vdots \end{bmatrix} (\vec{x} - \vec{x}^{(t)}) \end{aligned}$$

为求 $f(x)$ 最小，令

$$\begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x) \\ \vdots \end{bmatrix} \simeq \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix} + \begin{bmatrix} \vdots \\ \cdots \quad \frac{\partial^2 f}{\partial x_i \partial x_j}(x^{(t)}) \quad \cdots \\ \vdots \end{bmatrix} (\vec{x} - \vec{x}^{(t)}) = 0$$

即

$$\vec{x}^{(t+1)} = \vec{x}^{(t)} - \begin{bmatrix} \vdots \\ \dots & \frac{\partial^2 f}{\partial x_i \partial x_j}(x^{(t)}) & \dots \\ \vdots \end{bmatrix}^{-1} \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix}$$

### 2.2.1 拟牛顿法

$$\text{令 } \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)}) \stackrel{\text{def}}{=} \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t+1)}) \\ \vdots \end{bmatrix} - \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix}, \quad \Delta \vec{x}^{(t)} = \vec{x}^{(t+1)} - \vec{x}^{(t)}$$

$$\text{用 } H^{(t)} \text{ 近似 } \begin{bmatrix} \vdots \\ \dots & \frac{\partial^2 f}{\partial x_i \partial x_j}(x^{(t)}) & \dots \\ \vdots \end{bmatrix}, \text{ 或用 } G^{(t)} \text{ 近似 } \begin{bmatrix} \vdots \\ \dots & \frac{\partial^2 f}{\partial x_i \partial x_j}(x^{(t)}) & \dots \\ \vdots \end{bmatrix}^{-1},$$

则需满足拟牛顿条件

$$\Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)}) = H^{(t)} \Delta \vec{x}^{(t)} \quad \text{或} \quad G^{(t)} \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)}) = \Delta \vec{x}^{(t)}$$

则令

$$\vec{x}^{(t+1)} = \vec{x}^{(t)} - \lambda^{(t)} G^{(t)} \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix}$$

其中

$$\lambda^{(t)} = \operatorname{argmin}_{\lambda \geq 0} \left( \vec{x}^{(t)} - \lambda G^{(t)} \begin{bmatrix} \vdots \\ \frac{\partial f}{\partial x_i}(x^{(t)}) \\ \vdots \end{bmatrix} \right)$$

#### 2.2.1.1 BFGS

$$H^{(t+1)} = H^{(t)} + \frac{\Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)}) \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})^T}{\Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})^T \Delta \vec{x}^{(t)}} + \frac{H^{(t)} \Delta \vec{x}^{(t)} \Delta \vec{x}^{(t)T} H^{(t)}}{\Delta \vec{x}^{(t)T} H^{(t)} \Delta \vec{x}^{(t)}}$$

#### 2.2.1.2 DFP

$$G^{(t+1)} = G^{(t)} + \frac{\Delta \vec{x}^{(t)} \Delta \vec{x}^{(t)T}}{\Delta \vec{x}^{(t)T} \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})} + \frac{G^{(t)} \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)}) \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})^T G^{(t)}}{\Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})^T G^{(t)} \Delta \frac{\vec{\partial} f}{\partial x}(x^{(t)})}$$

## 2.3 有约束的迭代法

### 2.3.1 惩罚函数法

$$\begin{aligned} & \min f(x) \\ \text{s.t. } & h_i(x) = 0 \end{aligned}$$

近似于

$$\min f(x) + \sum_i \lambda_i h_i(x)$$

$\lambda_i \geq 0$ 作为惩罚力度

### 2.3.2 边界跟踪法

#### 2.3.2.1 法一

若每一步不违反约束，则忽略约束按正常梯度方向 $-\nabla f$ 走；若每一步违反约束，则按约束方向 $\nabla g_i$ 走

#### 2.3.2.2 法二

忽略约束走到终点。

若终点不违反约束，则完成；若终点违反约束，则按约束方向 $\nabla g_i$ 方向走直至不违反